

张目远

Agent 开发 | RAG / Agent 系统 | 后端工程 | 19829773360 | charlizezmy@charlizezmy@gmail.com



教育背景

西北工业大学

软件工程·硕士（软件学院）

- GPA 3.77 / 4.1, 专业排名 top 10%

软件工程·学士（软件学院）

- GPA 3.54 / 4.1, 专业排名 top 15%, 保研至本校软件学院

985 / 211 · 陕西西安

2024.09 - 至今

2020.09 - 2024.06

实习经历

大疆 DJI 研发管理与AI使能部·绩效管理组

2026.07 - 至今

绩效评估 Agent 平台 (rd-points)

系统级共建者 | 全栈/Agent 开发

Task Scheduling · Workflow Core · Claude SDK

- 项目背景: Platform (SpringBoot 编排中枢) + Sphere (Claude Agent 执行引擎) + FE (React) 三仓库协作: 定时拉取飞书/JIRA/Colla 任务, 调度 Sphere 用部门 Skill 打分并 Review, 产出员工负荷、部门健康度、贡献度排行等看板数据。
- Webhook → Redis Stream 可靠投递: Sphere 终态经 webhook 回调 Platform, 重启期间重试耗尽致结果滞留; 改为 Redis Streams 消费组: 终态与投递 Outbox 同事务提交, XADD 写入 (失败退避重试, 超限转 DEAD_LETTER), Platform XREADGROUP + XAUTOCLAIM 认领超时 PEL, 终态幂等把 at-least-once 收敛为 effectively-once, 仅事务提交成功后 XACK; 按 Run 灰度切流, Apollo 热更新驱动无锁切换。
- 贡献度助手 SSE 流式推送: EventSource 长连接 (5 分钟到期自动重连), 鉴权 + Redis INCR 限流后转线程池, XREAD BLOCK 阻塞轮询逐条转发; 写入侧 fencing token (Lua 原子脚本) 防旧执行轮次覆盖写入; 游标 (Last-Event-ID 优先) 实现断线续传, 失效时下发全量快照重建前端; 15s 心跳兼保活与权限热校验, Redis 故障降级为 stream.degraded; 多 Pod 场景下经 PostgreSQL 原子 claim 实现 relay 租约接管 (30s 租约/10s 续租), Pod 崩溃后由其他 Pod 按游标续接 Sphere 事件流, 配合 Redis Lua dedupe key 防重复业务事件。
- 权限与 MCP 委托安全链: 设计 service token + 短期 delegation 双因子鉴权, 每次 MCP 调用重新计算 scope fingerprint (不信任 run 创建时的权限快照), fingerprint 不一致立即撤销 delegation 并终止 run; 历史消息读取与下一轮提交前批量重新鉴权全部引用, 任一资源失权则整条助手消息降级为 SCOPE_CHANGED (隐藏正文/卡片/引用) 并递增 session_epoch 阻止 resume 旧 Session。
- 任务调度吞吐治理: 团队排查出调度端 N+1 查询、单线程串行提交等瓶颈; 落地 Quick Win (batch-size/interval-ms/poll-batch-size/Outbox fixedDelay 调优) + Phase 1 (消除 N+1、sphereEvalExecutor 并行化提交、超时自动失败兜底)。上线后 30 分钟完成率 23.27%→53.72%, 2 小时完成率 49.76%→85.81%, 8 小时以上长尾 20.84%→1.66%, 12 小时以上长尾清零。

AgentOps 沙箱管理 (rd-agent-be)

参与设计 + 部分实现 | Agent 代码执行沙箱资产管理

DDD 六层架构·状态机·事件驱动·OpenSandbox

- 项目背景: Agent 执行代码类任务需隔离沙箱环境, 此前 CPU/内存硬编码分配、不可视化管理; 引入阿里 OpenSandbox 作为底层运行时。
- DDD 六层架构 + 状态机设计: 参与 sandbox 领域六层架构 (facade/client/domain/infra/application/adaptor) 设计与部分实现——聚合根为纯状态机 (草稿→初始化→在线→下线/失败五态, 容器编排隔离在应用层, 领域不感知 OpenSandbox); submit 同步落库发领域事件, SandboxRunner 异步监听驱动容器供给 (成功转 online、失败转 FAILED, 状态前置校验兜底幂等); SandboxReconcileScheduler 定时对账 (Redisson 分布式锁) 校正脏态。

个人知识库 端到端链路 Owner | 从 0→1 构建 Plan-Verify-Replan 工作流与三层 Memory 架构 Agent

Python + LangGraph + FastAPI; 覆盖检索、验证、记忆、状态恢复与知识闭环

- 基于 LangGraph StateGraph 构建 Plan-Verify-Replan Agent，设计 Planner / Retriever / Answerer / Verifier / Replanner / KnowledgeLoop 六节点工作流；Verifier 基于 RAGAS Faithfulness 校验答案忠实性，未通过则触发重检索
- 设计 Hybrid Search (text-embedding-3-small + ChromaDB + BM25) + RRF 融合排序，引入 Query Expansion；构造 100+ 条 QA 评测集以 RAGAS 量化，Context Recall 相比 baseline 提升 36.6%，Faithfulness 达 0.843
- 设计三层 Memory 架构：LangGraph InMemoryStore 管理会话级短期记忆，Redis Hash 持久化用户长期阅读偏好与兴趣标签，PostgreSQL 存储历史问答记录；Memory 命中时跳过重复检索，平均响应延迟从 602ms 降至 2ms
- 基于 LangGraph Checkpoint (SqliteSaver) 实现 Step-level 状态持久化，检索或工具调用失败时自动回滚并触发降级策略（扩大 top-k / 放宽过滤条件），长链路任务故障恢复率 $\geq 95\%$
- 构建知识闭环机制：Agent 回答时若检测到笔记覆盖不足，自动生成补充摘要写回知识库，持续扩充个人知识图谱

基于 Spring Cloud 的电商交易系统

核心开发者

Spring Cloud 微服务架构; 覆盖库存、订单、检索与缓存链路

- 基于 Redis + Lua 实现库存原子扣减，在秒杀压测场景下实现高并发请求的库存一致性控制与超卖防护
- 引入 RocketMQ 构建异步订单链路，将下单流程异步化处理，实现削峰填谷并降低数据库瞬时写入压力
- 采用 Redis + Lua + Redisson 构建分层并发控制机制，在库存与非库存场景分别实现原子性扣减与防重复下单控制
- 采用 Canal + Binlog + MQ 构建最终一致性方案，以数据库变更为事件源，实现订单与库存的异步同步与状态修复
- 基于 Elasticsearch 构建商品多维检索能力，支持复杂条件过滤与排序优化；设计 Caffeine + Redis 二级缓存，构建本地缓存优先的热点访问路径，压测环境下显著降低数据库访问延迟

VideoSCI 视频压缩感知重建 (Differential Unfolding)

论文一作 (AAAI 2027 投稿中)

迭代框架重构与差分 Transformer 特征更新; 覆盖算法、训练与评测

- 针对 VideoSCI 重建中计算开销大、迭代后期特征更新停滞问题（导致资源浪费与性能受限），重构迭代框架，解耦稳定结构与动态更新，减少无效计算
- 基于差分 Transformer 优化特征更新方式，提升动态建模能力
- 结果：PSNR 提升超过 0.5 dB，参数量减少 50% 以上，计算量减少 33% 以上，实现更优的精度-效率权衡
- 论文状态：AAAI 2027 投稿中；代码：github.com/Muyuan-Zhang/DU

专业技能

- 后端开发：Java / Python，面向对象设计与常用集合框架，并发编程基础（JUC、线程池、锁机制）
- Web 框架：Spring Boot / Spring MVC / MyBatis / FastAPI，理解 IoC、AOP 原理及常见设计模式
- 中间件：MySQL / Redis / MQ / Elasticsearch / ChromaDB 等，缓存设计、消息队列削峰、分布式一致性
- 大模型应用：RAG / Agent 系统完整落地经验；LangGraph / LangChain，Plan-Verify-Replan 工作流、多层 Memory 设计与 Checkpoint 失败恢复